Nhận dạng rượu vang chất lượng cao

Từ 11 chỉ tiêu hóa lý – bộ dữ liệu Wine Quality (UCI): phương án cơ sở so với cải tiến

Bài tập nhóm cuối kỳ – Học phần Nhận dạng mẫu

Nguyễn Quốc Cường – Trần Như Đức

Giảng viên: ……

Bài toán: thay hội đồng nếm bằng phép đo hóa lý?

- Đầu vào: 11 chỉ tiêu hóa lý (độ cồn, axit, đường dư, SO_2, tỉ trọng…) + loại rượu đỏ/trắng
- Đầu ra: chất lượng cao (điểm cảm quan ≥ 7) hay thường
- Dữ liệu thật: rượu Vinho Verde, Bồ Đào Nha, 2004–2007 (Cortez et al., UCI #186)
- Mục tiêu: vượt phương án cơ sở có kiểm định, hiểu mô hình sai ở đâu

6.497

mẫu gốc

1.177

bản ghi trùng → loại

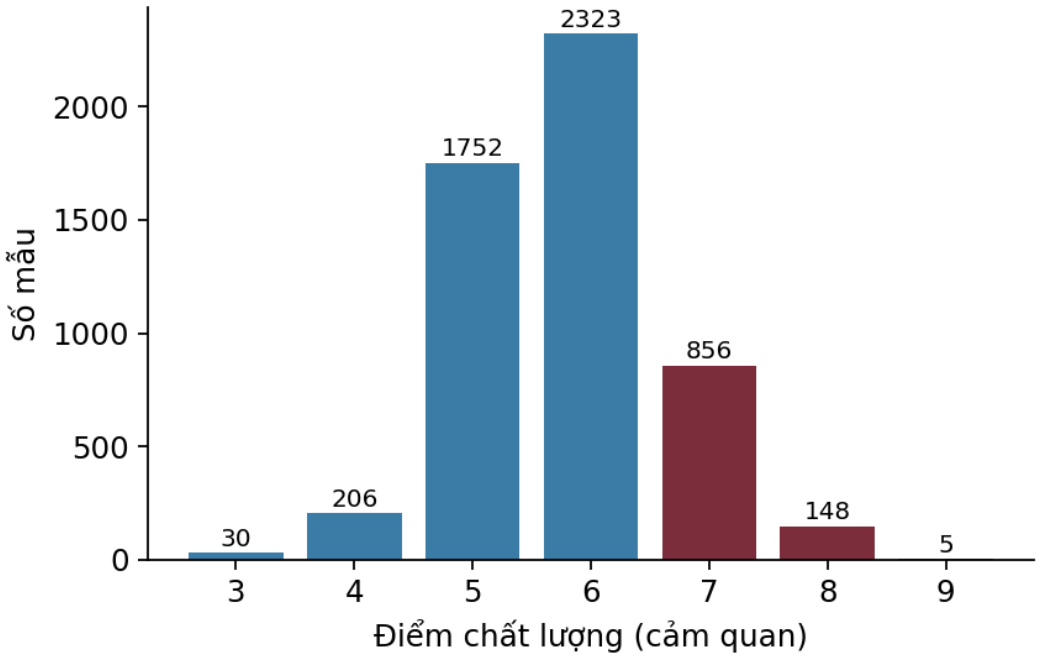
5.320

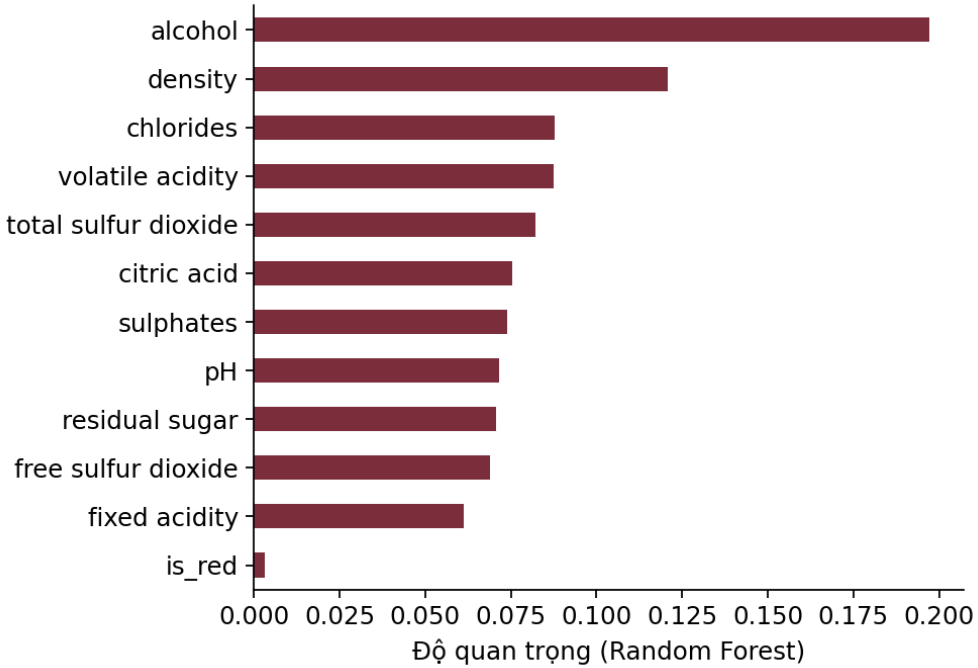
mẫu sử dụng

19%

lớp chất lượng cao

Dữ liệu: lớp thiểu số, chồng lấp mạnh, độ cồn dẫn dắt





- Chỉ 19% mẫu đạt ≥ 7 → accuracy gây hiểu nhầm; dùng F1, recall, AUC
- Độ cồn quan trọng nhất; hai lớp chồng lấp trên mọi chỉ tiêu, PCA cần 9/12 thành phần cho 95% phương sai

Phương án cơ sở và cải tiến

Cơ sở

- k-NN (k=5) trên đặc trưng thô
- Naive Bayes Gaussian
- Tham chiếu: luôn đoán lớp đa số

Cải tiến / thay thế

- Chuẩn hóa z-score
- Trọng số cân bằng lớp
- Logistic, LDA/QDA, SVM RBF, PCA + SVM
- Random Forest, Gradient Boosting
- Chọn đặc trưng; hồi quy thứ bậc (SVR)
- Chọn ngưỡng quyết định tối ưu F1

Quy trình đánh giá

Loại trùng

1177 bản ghi – tránh rò rỉ

5×3 CV

phân tầng, 15 fold

Nested

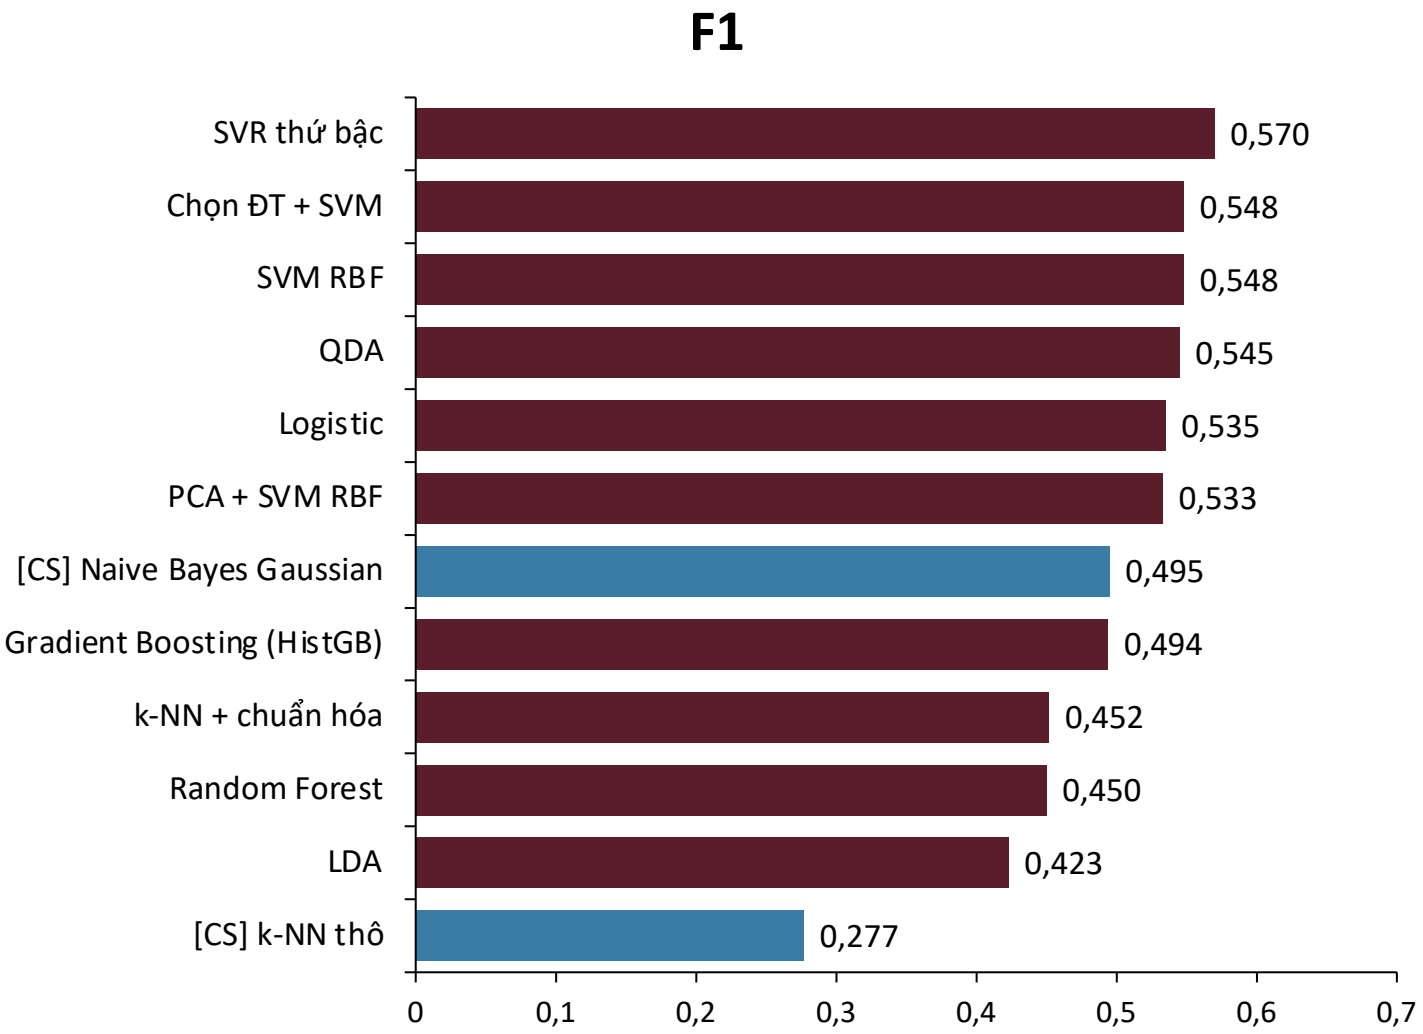
GridSearch trong mỗi fold

t-test

hiệu chỉnh Nadeau–Bengio

- Chỉ số chính: F1 và recall của lớp chất lượng cao, ROC-AUC; accuracy chỉ để tham khảo
- Phân tích lỗi trên dự đoán ngoài-fold cho toàn bộ 5.320 mẫu; seed = 42

Kết quả: F1 tăng gần gấp đôi so với cơ sở



0,277 → 0,548

F1: k-NN thô → SVM RBF

0,570

F1 cao nhất: SVR thứ bậc; mọi cải tiến $p < 0,001$

Xanh: cơ sở; đỏ rượu: cải tiến. F1 ở ngưỡng mặc định.

Vì sao không dùng accuracy

Mô hình	Accuracy	Recall	F1
[TC] Lớp đa số	81,0%	0,0%	0,000
[CS] k-NN thô	79,2%	21,0%	0,277
k-NN + chuẩn hóa	83,4%	36,2%	0,452
SVM RBF	74,7%	80,9%	0,548

Đoán 'thường' cho mọi chai:

accuracy 81%

nhưng không tìm được chai ngon nào

- Chuẩn hóa: F1 0,277 → 0,452 (SO_2 ~ 10^2 lấn át độ cồn ~ 10)
- Thêm cân bằng lớp (SVM): recall 36% → 81%

Thử theo gợi ý của UCI: chọn đặc trưng, nhãn có thứ tự

Chọn đặc trưng (ANOVA F + SVM)

k = 12/12

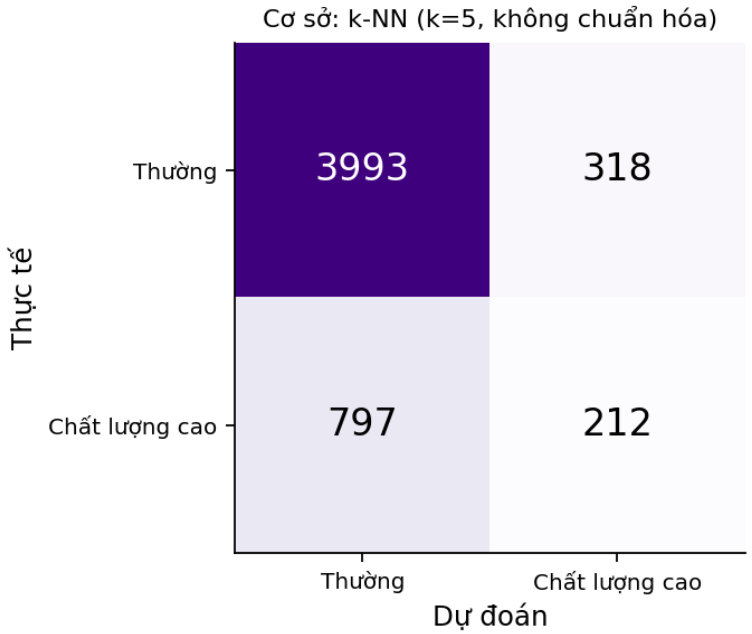
- F1 0,548 so với SVM đầy đủ 0,548
- Nested CV giữ lại gần như mọi chỉ tiêu: mỗi chỉ tiêu đóng góp một ít

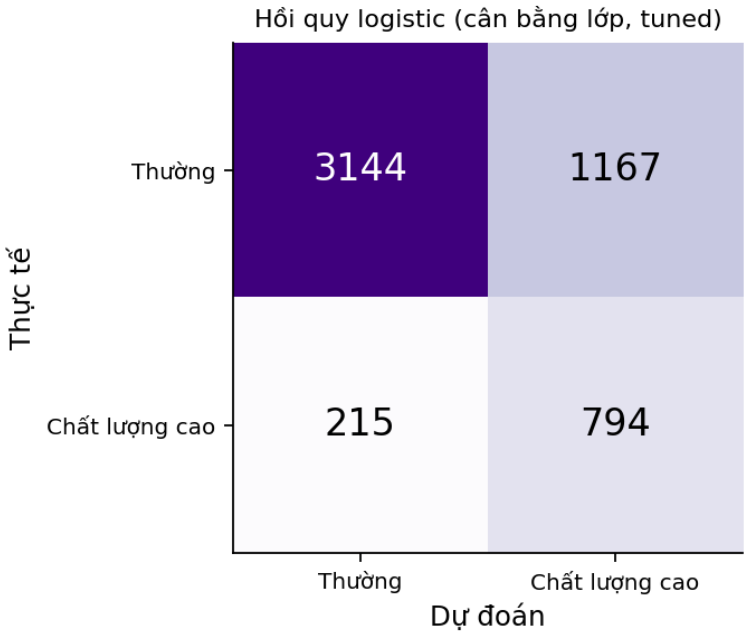
Hồi quy thứ bậc (SVR điểm → ngưỡng)

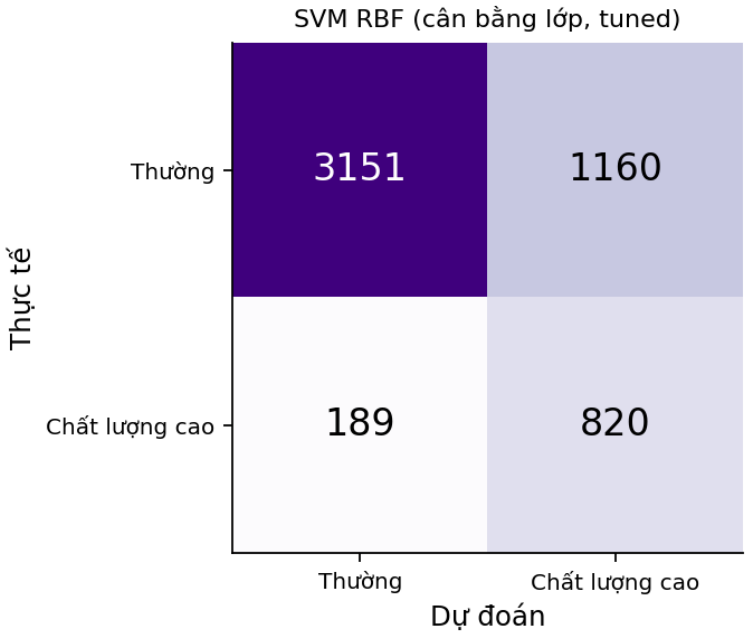
F1 0,570

- Recall 69%, precision 49%, AUC 0,852
- Dự đoán điểm 3–9 rồi cắt ở ≈ 6,12; hơn SVM với p = 0,04
- Tận dụng thứ tự: điểm 6 gần lớp dương hơn điểm 4

Ma trận nhầm lẫn: đổi bỏ sót lấy báo nhầm

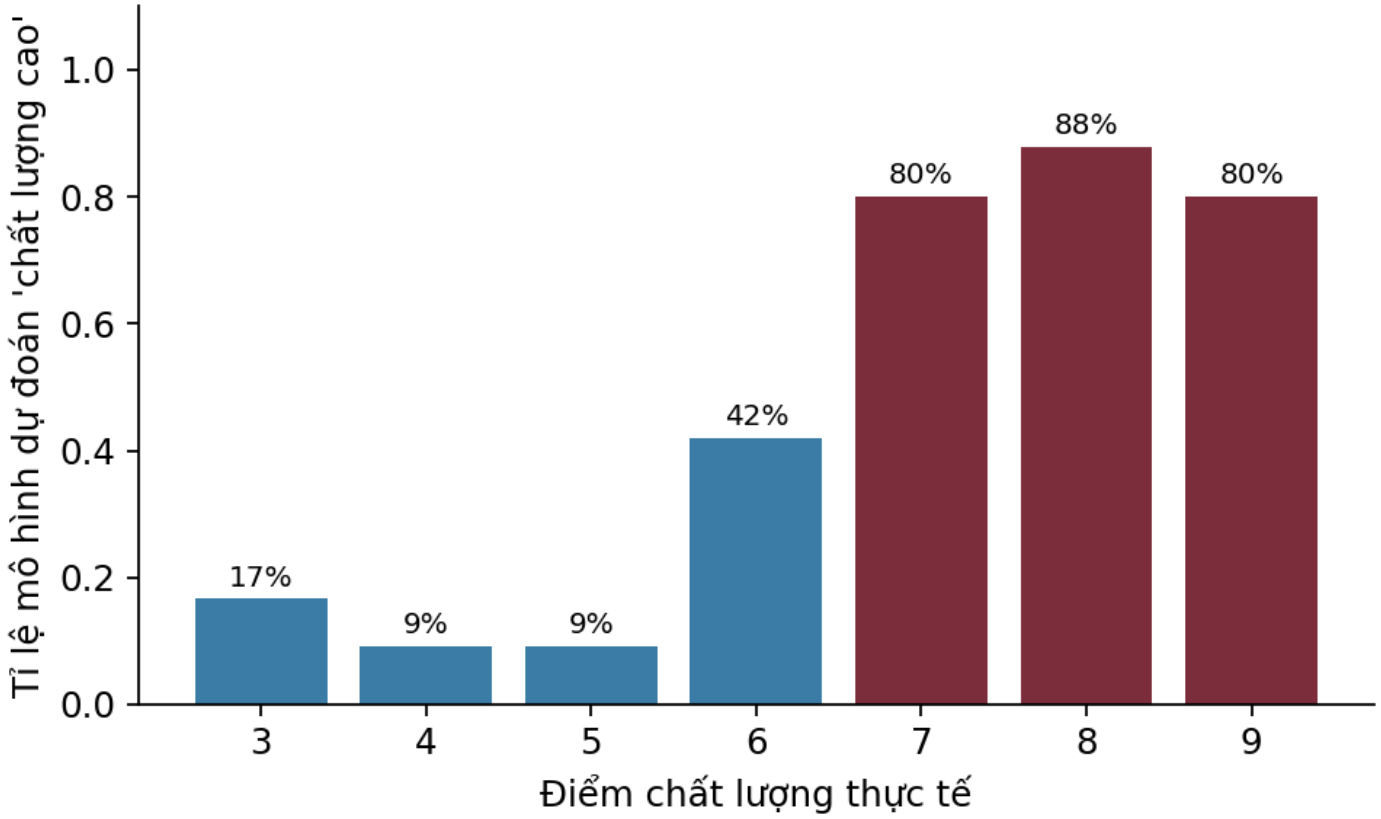






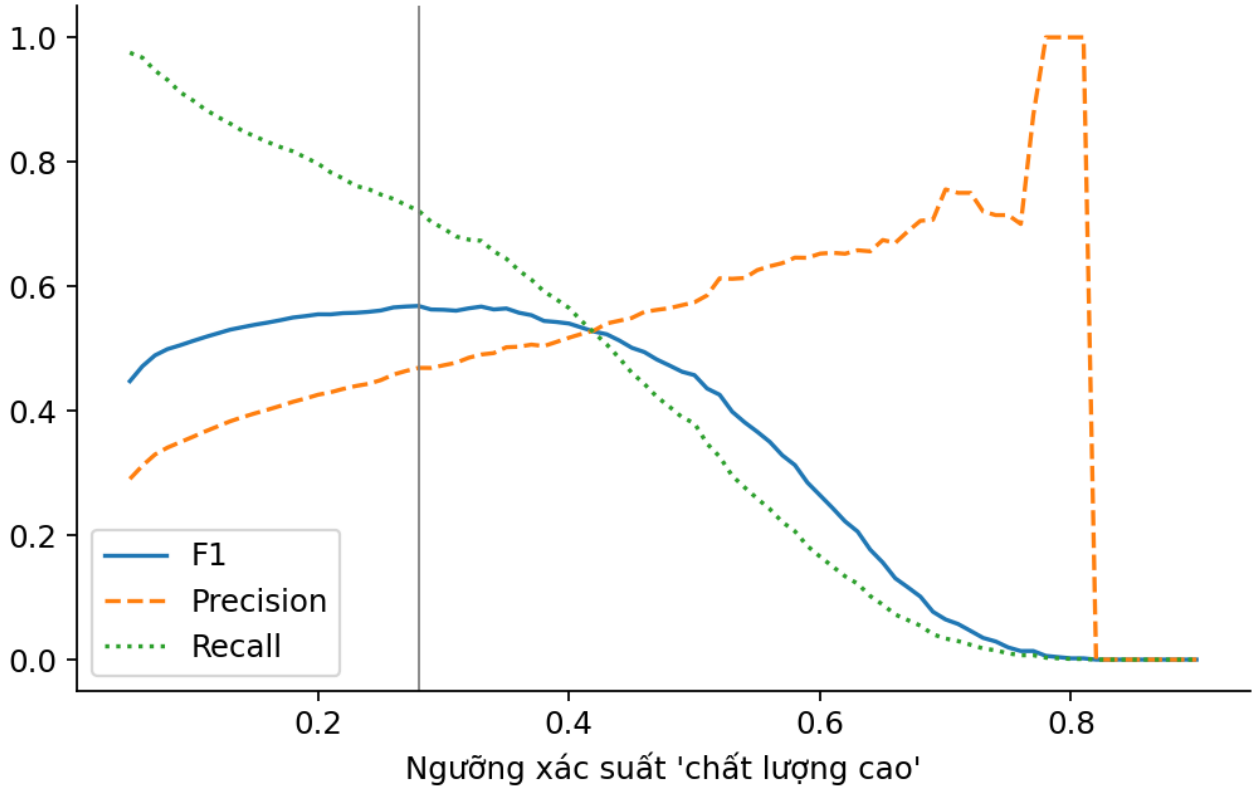
- Bỏ sót rượu ngon: 797 → 189 | Báo nhầm: 318 → 1160
- Precision ~0,4: sàng lọc tốt, nhưng chưa thay được hội đồng nếm

84% báo nhầm là rượu điểm 6 – sát ranh giới



- Tỉ lệ đoán 'cao' tăng theo điểm thật: 9% (5) → 42% (6) → 80% (7)
- Bỏ sót: rượu ngon có độ cồn thấp
- Báo nhầm: rượu thường có độ cồn cao
- Mô hình phụ thuộc quá nhiều vào độ cồn

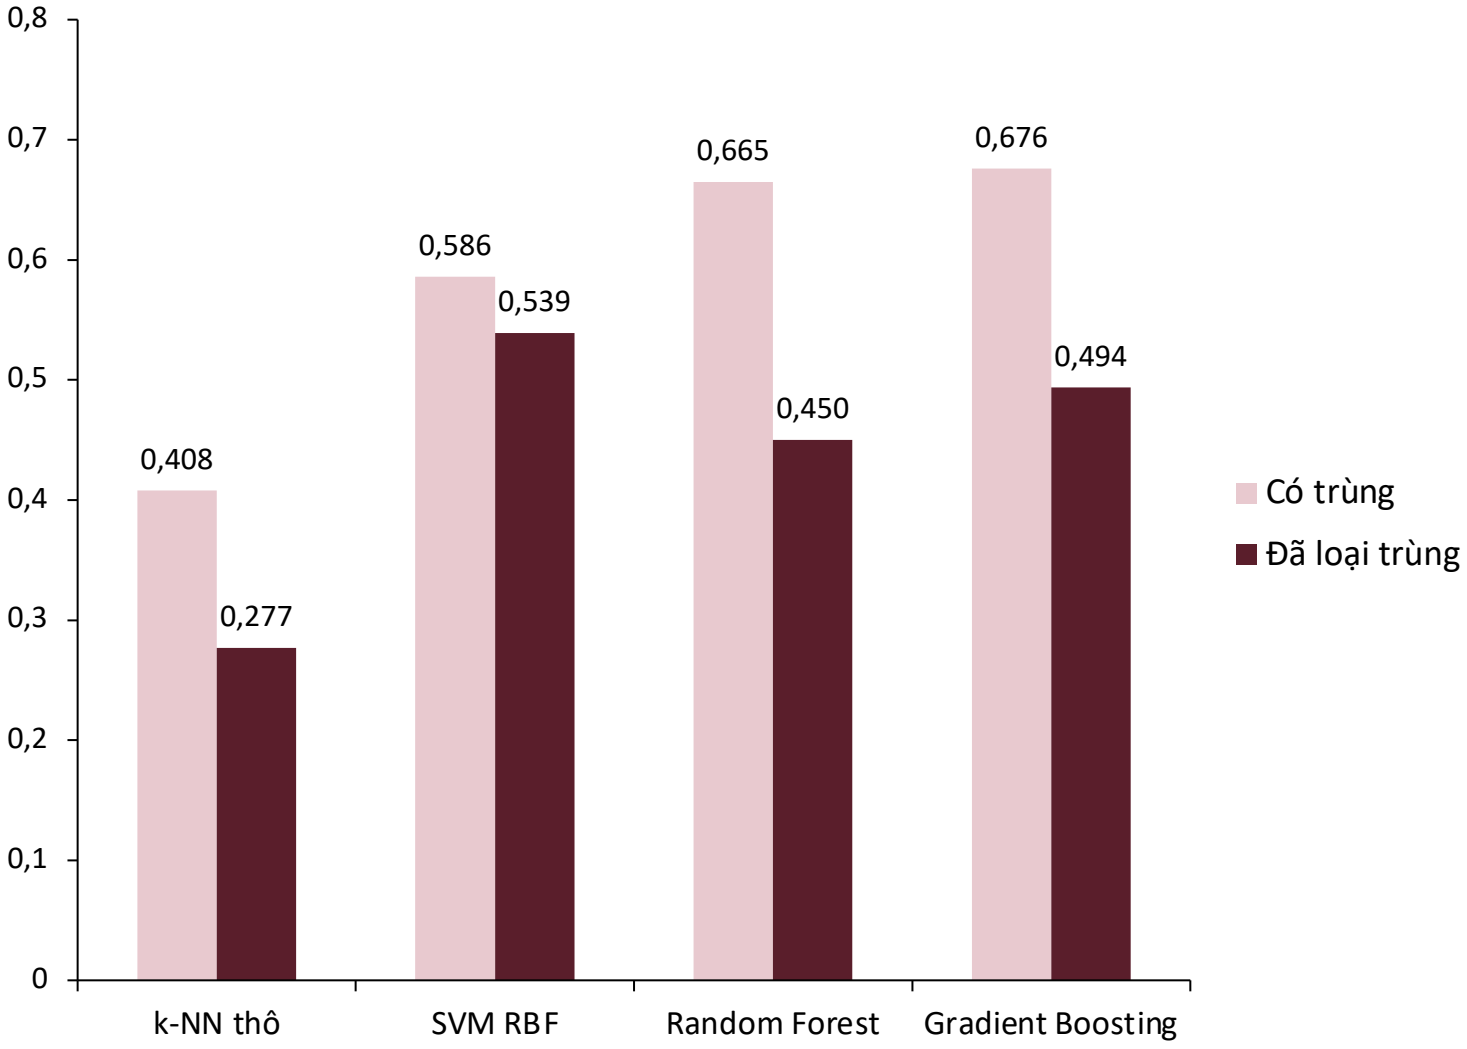
Ngưỡng quan trọng ngang chọn mô hình



Mô hình	F1 @0,5	F1 tối ưu
Random Forest	0,443	0,582
SVM RBF	0,457	0,568
Gradient Boosting (HistGB)	0,490	0,559
Logistic	0,535	0,542
k-NN + chuẩn hóa	0,445	0,531
[CS] k-NN thô	0,276	0,403

Sau khi chỉnh ngưỡng, các mô hình mạnh chỉ còn chênh 0,01–0,04

Bản ghi trùng thổi phồng mô hình cây



- 1177 bản ghi trùng (18%)
- Random Forest: F1 0,665 → 0,450
- SVM: chỉ 0,586 → 0,539
- Không loại trùng → chọn sai mô hình

Điều chưa giải quyết được

Nhãn chủ quan

Ranh giới 6/7 có nhiễu, tạo trần hiệu năng

Thiếu thông tin

Không có giống nho, năm, hương vị; chỉ rượu Vinho Verde 2004–2007

Precision thấp (~0,4)

Chỉ dùng làm công cụ sàng lọc, chưa thay được hội đồng nếm

Đánh giá còn lạc quan

Ngưỡng chọn trên dữ liệu ngoài-fold, chưa có tập kiểm tra độc lập

Demo: thao tác trực tiếp với dữ liệu

- Chọn mẫu có sẵn hoặc lấy ngẫu nhiên một chai ngon
- Kéo 11 thanh chỉ tiêu hóa lý, đổi loại rượu
- So sánh k-NN cơ sở và SVM cải tiến
- Kéo ngưỡng để thấy đánh đổi bỏ sót / báo nhầm
- Đường xác suất theo độ cồn; vị trí trên PCA
- Tải CSV để dự đoán hàng loạt

streamlit run app.py

→ localhost:8501

Kết luận

0,277 → 0,548

F1: chuẩn hóa + cân bằng lớp + SVM RBF

Thứ bậc: 0,570

SVR trên điểm: F1 cao nhất

Loại trùng

bắt buộc; lỗi dồn ở ranh giới 6/7

Phù hợp làm công cụ sàng lọc hỗ trợ, chưa thay thế đánh giá cảm quan.

Phân công và tài liệu tham khảo

Thành viên	Nhiệm vụ	Đóng góp
Nguyễn Quốc Cường	Phân tích bài toán, làm slide	50%
Trần Như Đức	Code thuật toán, làm báo cáo	50%

[1] Cortez et al. 2009. Wine Quality, UCI: archive.ics.uci.edu/dataset/186

[2] Cortez et al. 2009. Decision Support Systems 47(4)

[3] Pedregosa et al. 2011. scikit-learn, JMLR 12

[4] Nadeau & Bengio 2003. Machine Learning 52